Diversità semantica nel campione di brevetti

Dalla classificazione WIPO al clustering dei testi

Analisi esplorativa CNR–ISTAT

10 novembre 2026



Perché analizziamo il contenuto dei brevetti?

Campionamento WIPO

32 campi $\times$ 2.000 selezioni
Distribuzione progettata per coprire campi tecnologici diversi.

$\not\Rightarrow$

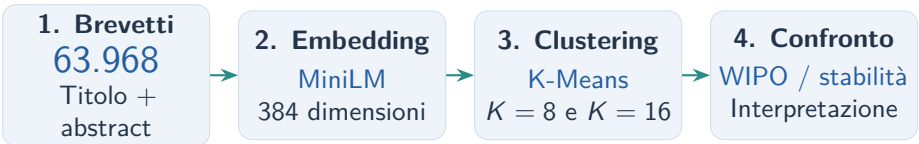
Diversità semantica

Che cosa descrivono i testi?
Le invenzioni potrebbero essere simili anche in campi differenti.

Domanda principale: il nuovo corpus mostra gruppi di invenzioni semanticamente distinguibili, e come si collegano ai campi WIPO?

La classificazione WIPO descrive un'area tecnologica; l'embedding prova a rappresentare il significato di titolo e abstract.

Che cosa abbiamo fatto: una pipeline in quattro passaggi

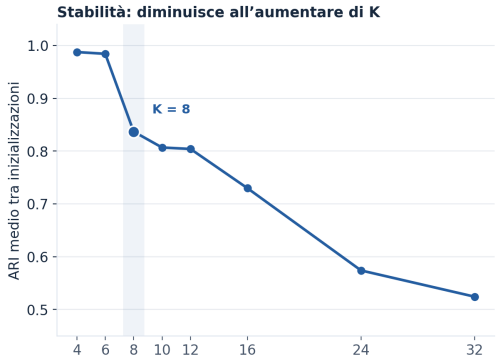


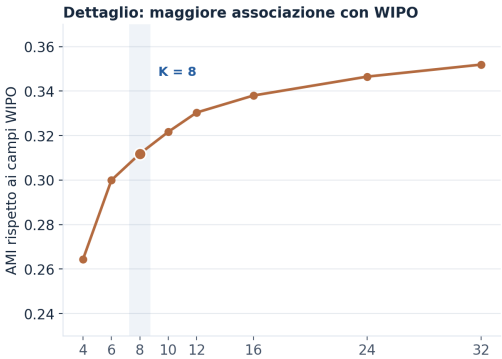
Perché MiniLM?
Trasforma testi in vettori: documenti con contenuto simile tendono ad avere rappresentazioni simili.

Un accorgimento importante
Per i testi lunghi usiamo finestre sovrapposte e combiniamo gli embedding; il limite base è 256 token.

I codici WIPO **non** entrano nei vettori: vengono usati solo dopo, per interpretare i gruppi.

Prima il pilota: perché otto cluster?





Meno cluster: gruppi più ampi e stabili.
$K = 8$: ARI tra inizializzazioni $\simeq 0{,}837$.

Più cluster: maggiore dettaglio, meno stabilità.
$K = 16$: ARI $\simeq 0{,}730$.

Pilota: 6.400 brevetti (200 per campo WIPO). Sono state valutate soluzioni da K=4 a K=32. K=8 è una scelta descrittiva, non un "numero vero" di tecnologie.

L'analisi completa: tutti i brevetti del corpus

63.968
pubblicazioni uniche incluse nell'analisi

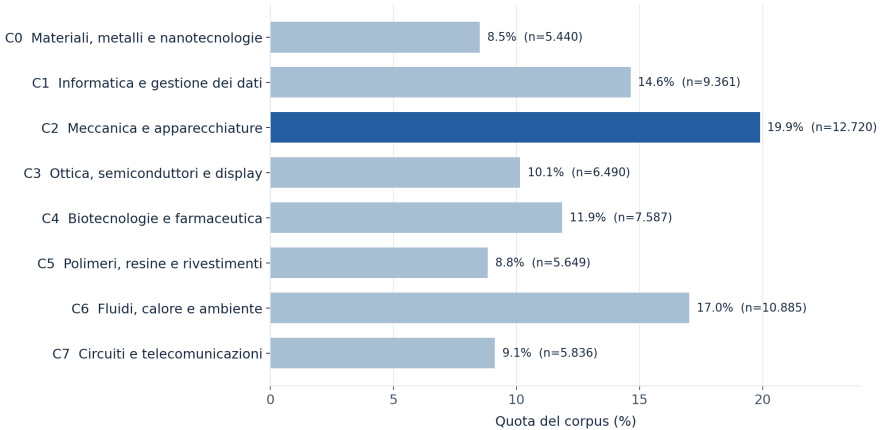
32
campi WIPO su 35 complessivi

28,0%
testi lunghi gestiti con chunking

Indicatore	$K = 8$	$K = 16$
Silhouette (coseno; campione di 1.200)	**0,065**	0,050
AMI rispetto al campo WIPO	0,311	**0,338**
Quota del cluster più grande	19,9%	9,5%

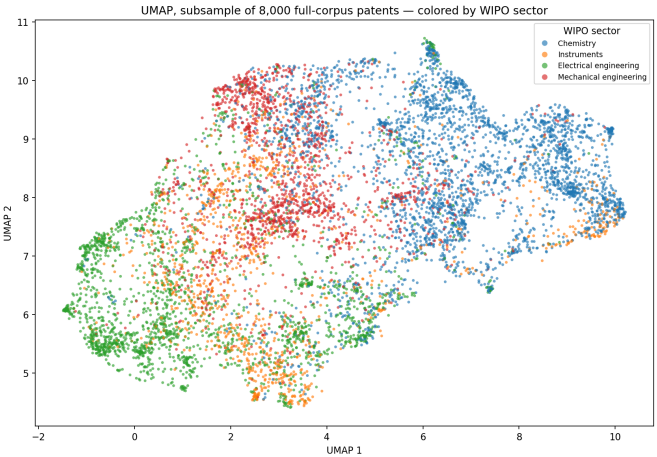
Il valore basso della silhouette indica che i gruppi si sovrappongono: non è una separazione "netta".

Otto gruppi ampi: quali tecnologie emergono?



Etichette descrittive proposte da parole distintive e composizione WIPO

Visualizzazione 2D: come si distribuiscono i settori WIPO?

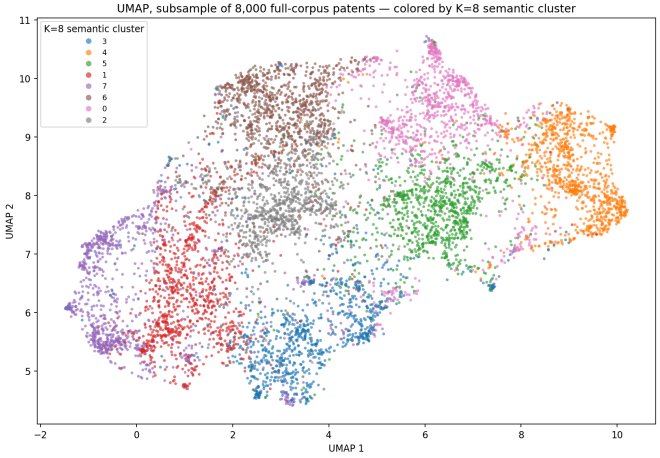


Come si legge

- Ogni punto rappresenta un brevetto (sottocampione di 8.000 brevetti).
- Punti vicini hanno contenuto semantico più simile.
- I colori mostrano il settore WIPO, **non** i cluster.

Messaggio Si osservano **zone con prevalenze diverse** (ad es. electrical più a sinistra/basso, chemistry più a destra), ma con **forte sovrapposizione**. Questo suggerisce che i settori WIPO sono informativi, ma non separano perfettamente i testi.

Visualizzazione 2D: i cluster semantici risultano più compatti



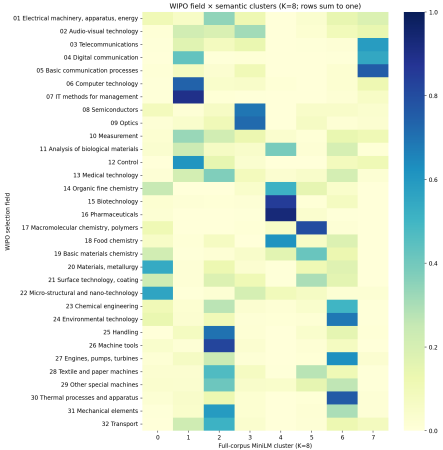
Cosa mostra

- Gli stessi 8.000 brevetti, ma colorati per cluster semantico $K = 8$.
- Alcune aree appaiono **più compatte e contigue**.
- Restano comunque **confini sfumati** tra gruppi vicini.

Interpretazione La mappa é coerente con gli altri indicatori: esiste una struttura semantica leggibile, ma **non** fatta di isole perfettamente separate. Per questo parliamo di gruppi descrittivi plausibili, non di classi nette.

Questa figura aiuta a comunicare intuitivamente perché K=8 funziona come segmentazione ampia: i gruppi sono visibili, pur con alcune sovrapposizioni.

I gruppi hanno una relazione plausibile con WIPO



Come si legge

Ogni riga è un campo WIPO; i colori indicano la quota assegnata a ciascun cluster. **Ogni riga somma a 100%.**

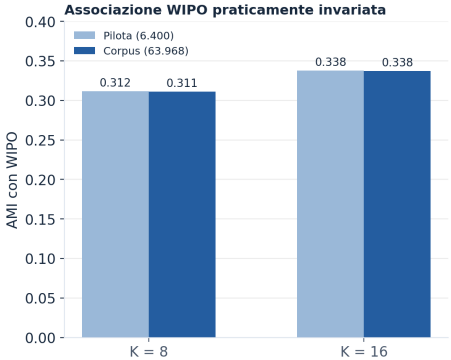
Esempi visibili

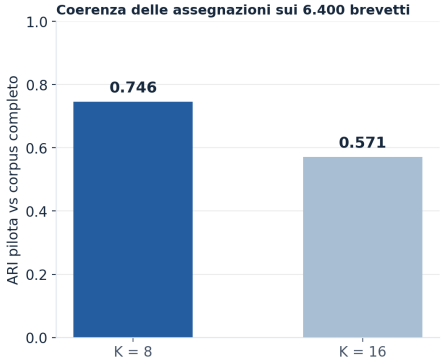
- Informatica → cluster 1
- Ottica/semiconduttori → cluster 3
- Biotech/farmaceutica → cluster 4
- Comunicazioni → cluster 7

I cluster non ripetono perfettamente i campi WIPO: li attraversano.

Figura da Google Drive: semantic_results_v6_full_corpus/full_WIPO_heatmap_K8.png.

La struttura si conserva dal pilota al corpus completo?





Associazione WIPO: quasi invariata passando da 6.400 a 63.968 brevetti.

Assegnazioni: maggiore accordo a $K = 8$ (ARI $= 0{,}746$) che a $K = 16$ (ARI $= 0{,}571$).

L'ARI confronta le partizioni sui medesimi 6.400 brevetti, dopo aver rifatto K-Means sull'intero corpus; 1 significa piena coincidenza.

Un limite importante: il cluster meccanico “generico”

19,9%

del corpus: cluster 2
12.720 brevetti

Parole frequenti
plate, arranged, rod, utility model, fixed, mechanism.

Due spiegazioni possibili

1. Somiglianza reale tra componenti e funzioni meccaniche.
2. Stile descrittivo standardizzato, non necessariamente una stessa tecnologia.

L’86,3% di questo cluster proviene dall’ufficio CN.

Cautela: l’associazione complessiva tra cluster e ufficio è bassa (AMI $\approx 0{,}039$), ma non esclude effetti di linguaggio in singoli gruppi.

Risposta alla domanda iniziale e prossimi passi

Risposta sintetica: il corpus mostra **eterogeneità semantica descrivibile**, con grandi aree tecnologiche plausibili e una struttura che persiste nel passaggio dal pilota all'analisi completa.

Cosa possiamo sostenere

- 8 gruppi ampi, interpretabili in via preliminare;
- corrispondenza parziale con WIPO;
- risultati del pilota coerenti col corpus.

Cosa resta da verificare

- coerenza reale delle etichette (revisione qualitativa);
- dipendenza da formule linguistiche generiche;
- **miglioramento rispetto al vecchio campione**.

Decisione da discutere: vogliamo descrivere la diversità interna al nuovo campione oppure misurarne il miglioramento rispetto alla selezione precedente?

Aggiornamento: dal primo EDA al benchmark dei modelli

Obiettivo del progetto

- Verificare se il campione stratificato per **WIPO** mostra anche **eterogeneità semantica**.
- Capire *quali* tecnologie e funzioni vengono associate dai testi.
- Passare da un esperimento con **MiniLM** a un confronto riproducibile di modelli.

64.000
selezioni iniziali, 32 campi WIPO

↓

63.968
pubblicazioni uniche analizzate

WIPO: 35 campi tecnologici in 5 settori; qui sono inclusi 32 campi (escluso il settore "Other fields", 3 campi). Campionamento progettato, non rappresentativo dell'universo dei brevetti.

Che cosa abbiamo già fatto? Notebook e output

Notebook	Analisi effettuata	Esito
03–05	EDA: struttura, testi, IPC e sovrapposizione WIPO.	Descrizione
06 v1–v2	Pilota 640 e poi **6.400** brevetti; MiniLM vs TF-IDF+SVD.	Pilota
06 v3	Robustezza a troncatura e inizializzazioni.	Diagnostica
07	Confronto $K = 4$–32; selezione e profili.	$K = 8$ base
08	Selezione di 120 casi per revisione qualitativa.	**0 annotati**
09	Embedding + K-Means su **63.968** brevetti; confronto col pilota.	Completo

La procedura completa è riproducibile: notebook e output sono salvati separatamente per ogni fase. Vedi elenco dei nomi file in appendice.

File esatti dei notebook utilizzati

EDA e sviluppo

`03_eda_structure.ipynb`

`04_eda_text.ipynb`

`05_eda_ipc_and_overlap.ipynb`

`06_semantic_validation_colab.ipynb`

`06_semantic_validation_pilot_v2.ipynb`

`06_semantic_validation_robustness_v3.ipynb`

Selezione di K e corpus completo

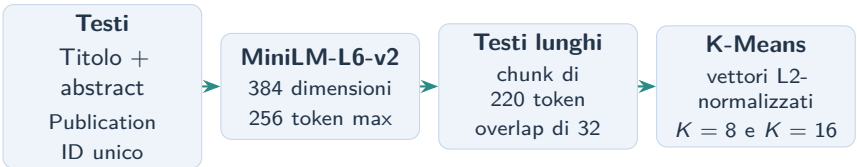
`07_semantic_clusters_k_selection_manual_review_colab.ipynb`

`08_semantic_clustering_K8_manual_validation_colab.ipynb`

`09_full_corpus_minilm_clustering_colab.ipynb`

Cartelle Google Drive: `MyDrive/istat_patents/semantic_results_v3`, `semantic_results_v4_k_comparison`, `semantic_results_v6_full_corpus`.

Pipeline attuale: preprocessing e clustering



Trattamento dei testi

- **17.937 brevetti (28,0%)** richiedono chunking.
- Media pesata degli embedding dei chunk; nuova normalizzazione L2.

Valutazione

- Silhouette *coseno*, AMI/NMI con WIPO, ARI di stabilità, dimensioni cluster.
- WIPO non usato come input: solo confronto esterno.

Input: `patents_2021-2026_by_publication.parquet` e `patents_2021-2026_by_field.parquet`; notebook completo: `09_full_corpus_minilm_clustering_colab.ipynb`.

Baseline quantitativa: risultati da mantenere come riferimento

Corpus completo	$K = 8$	$K = 16$
Silhouette (coseno; $n = 1.200$)	**0,065**	0,050
AMI con campo WIPO	0,311	**0,338**
AMI con ufficio brevetti	0,039	0,037
Cluster più grande	19,9%	9,5%
ARI pilota vs corpus*	**0,746**	0,571

* ARI calcolato sugli stessi 6.400 brevetti presenti in entrambi gli esperimenti.

Interpretazione

- **Struttura plausibile**, ma gruppi poco separati (silhouette bassa).
- Allineamento **parziale** con WIPO; AMI non è accuratezza.
- $K = 8$ ha una struttura più riproducibile tra pilota e corpus completo.

Attenzione a C2 ($K = 8$): 12.720 brevetti (19,9%); **86,3% dell'area C2** ha codice ufficio `CN`. Possibile mix tra contenuto meccanico e linguaggio standardizzato; **non ancora dimostrato**.

Tre articoli, due linee di ricerca

Ghosh e colleghi: PaECTER

arXiv 2024 $\longrightarrow$ PLOS ONE 2026

- Lo studio del 2026 è la versione pubblicata e ampliata dello stesso lavoro.
- Patenti con citazioni degli esaminatori come segnale di similarità.
- Confronta **PaECTER** e, nel preprint, **PAT SPECTER**.

Ascione e Sterzi (2024)

Studio indipendente

- Confronta embedding statici e transformer per *patent similarity*.
- Mostra il valore del **fine-tuning sul dominio**.
- Propone **Patent SBERT-adapt-ub**, derivato da MiniLM.

Riferimenti: Ghosh et al., 2024, arXiv:2402.19411; Ghosh et al., 2026, PLOS ONE 21:e0358188; Ascione & Sterzi, 2024, arXiv:2403.16630.

Quali embedding model possiamo testare?

Modello / origine	Dim.	Token	Ipotesi da testare
MiniLM-L6-v2 (baseline)	384	256	Riferimento general-purpose già utilizzato.
Patent SBERT-adapt-ub	384	512	Quanto aiuta il fine-tuning sui brevetti, a parità di dimensioni?
PaECTER (BERT for Patents)	1.024	512	Il modello addestrato con citazioni separa meglio i brevetti?
PAT SPECTER (SPECTER2)	768	512	Secondo encoder specializzato, opzionale.

Confronto prioritario: MiniLM → SBERT-adapt-ub → PaECTER.

I risultati degli articoli riguardano soprattutto similarity e retrieval: non garantiscono un clustering migliore sul nostro corpus.

Che cosa aggiungono gli articoli alla nostra metodologia?

Ghosh et al. (2026)

- Usano **titolo + abstract**, come il nostro dataset.
- Addestrano PaECTER su **300.000 famiglie** EPO tramite citazioni.
- **Mean pooling** delle rappresentazioni token; input fino a 512 token.
- Supporta un benchmark **patent-specific**, non solo general-purpose.

Ascione & Sterzi (2024)

- Validano la similarità tramite coppie di **patent interferences**.
- Mostrano che **adattare il modello al dominio** può contare più della sola architettura.
- Utile per impostare un **confronto di modelli** e non scegliere per sola dimensione.

Domanda nuova: possiamo migliorare la rappresentazione semantica *senza* passare subito a modelli molto grandi e costosi?

Benchmark controllato: quale modello migliora il clustering?

Tenere costante

- **6.400 brevetti** identici del pilota; poi estendere al corpus.
- Stesso testo (titolo + abstract) e regole di pulizia.
- **L2**, K-Means ($K = 8, 16$), seed, campione silhouette.
- Valutare i limiti di 256 vs 512 token con un test dedicato.

Registrare per ogni modello

- Silhouette (coseno); AMI con WIPO; stabilità ARI.
- Dimensioni dei cluster; termini distintivi; casi periferici.
- **Tempo, memoria GPU, throughput**, token tagliati.
- Coerenza con brevetti etichettati, se disponibili.

WIPO è un riferimento esterno, non un gold standard perfetto: un modello può scoprire gruppi trasversali ai campi WIPO. Confrontare metriche calcolate con identiche impostazioni.

Nuove prove I: quali parti del testo contano?

Segmentazione dell'abstract

- Produrre embedding di **frasi** o **paragrafi** separati.
- Confrontare primo e ultimo segmento con il vettore dell'intero brevetto.
- Misurare quando cambia l'assegnazione usando gli **stessi centroidi**.

Esperimento C2 / CN

- Confrontare K-Means **con e senza** i brevetti CN di C2.
- Usare un'esclusione **casuale di pari dimensione** come controllo.
- Verificare silhouette, AMI, ARI e composizione WIPO.

Il chunking dei testi lunghi è già implementato; il test sui segmenti risponde a una domanda *nuova*. In C2, 86,3% degli elementi sono CN, mentre C2 è il 19,9% del corpus.

Nuove prove II: i cluster sono coerenti ai margini?

Verifica dei casi periferici

- Selezionare **5 brevetti periferici** per cluster (lontani dal centro e diversi tra loro).
- Leggere titolo + abstract e confrontare con l'etichetta tecnologica proposta.
- Distinguere coerenza reale da linguaggio standard.

Clustering alternativo (opzionale)

- Provare un approccio basato sulla densità, come **HDBSCAN**, su un pilota.
- Per il **bi-clustering**, usare una matrice interpretabile di *termini* $\times$ *brevetti*.
- Confrontare le soluzioni senza imporre gruppi sferici.

I cluster non sono stati ancora validati manualmente: notebook 08 ha preparato 120 osservazioni, ma non contiene valutazioni completate.

Roadmap per il prossimo incontro e il workshop

1. **Prima**: test rapido MiniLM / Patent SBERT-adapt-ub / PaECTER sullo stesso pilota.
2. **Poi**: scegliere un modello; test di robustezza su frasi, paragrafi e sottoinsieme CN di C2.
3. **Infine**: confronto su **63.968** brevetti, casi periferici, eventuali algoritmi alternativi.

Output per il workshop

- **Tabella di benchmark**
- **Profili e visualizzazioni**
- **Limiti / costo GPU**
- **Ipotesi per ricerca successiva**

Con Mauro: verificare anche il checkpoint esatto del modello Qwen citato da Mario/Federico (possibile confronto LLM successivo). Workshop di dicembre: invio indicato entro fine novembre, da verificare.

Riferimenti e modelli: collegamenti operativi

- **Ghosh et al. (2026).** *PaECTER: Patent-level representation learning using citation-informed transformers*. PLOS ONE 21(10), e0358188.
  doi:10.1371/journal.pone.0358188 HF: mpi-inno-comp/paecter
- **Ghosh et al. (2024).** *PaECTER*, versione arXiv:2402.19411v1; include il confronto diretto con **PAT SPECTER**.
  HF: mpi-inno-comp/pat_specter
- **Ascione & Sterzi (2024).** *A comparative analysis of embedding models for patent similarity*. arXiv:2403.16630v1.
  HF: graziasveva93/sbert-adapt-ub

Modelli proposti per benchmarking: non costituiscono risultati già ottenuti sul nostro corpus.

Appendice — Dal dettaglio ($K = 16$) ai gruppi ampi ($K = 8$)

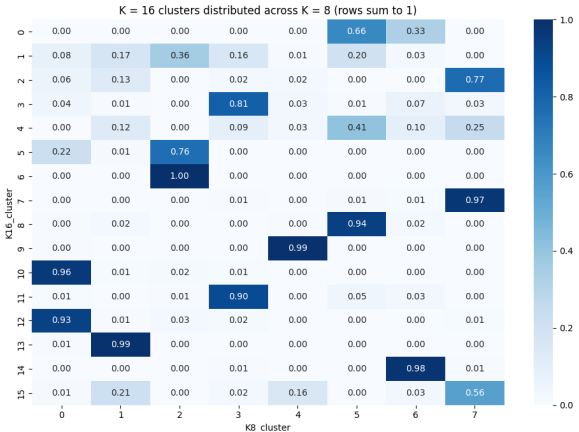


Figura del pilota, non del corpus completo. K-Means è stimato separatamente per ciascun K: i gruppi non sono necessariamente perfettamente annidati.

Appendice — Tre indicatori, tre domande diverse

Indicatore	Che cosa misura?	Come interpretarlo qui?
Silhouette	Separazione/cohesione dei gruppi nello spazio dei vettori.	0,065: confini sfumati; non forti isole semantiche.
AMI	Associazione tra clustering e campo WIPO, corretta per il caso.	$\approx$ 0,31: relazione informativa ma non coincidenza perfetta.
ARI	Somiglianza di due partizioni sugli stessi brevetti, corretta per il caso.	0,746: concordanza sostanziale tra pilota e corpus per K=8.

WIPO è un confronto esterno, non un ground truth semantico. Il corpus copre 32 dei 35 campi WIPO.